

UNIVERSIDADE FEDERAL DE SERGIPE
UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE

PROGRAMA DE PÓS-GRADUAÇÃO EM DEMOGRAFIA
DOUTORADO INTERINSTITUCIONAL EM POPULAÇÃO,
ESTATÍSTICAS SOCIAIS E POLÍTICAS PÚBLICAS

PROF. KLEBER OLIVEIRA

**TÓPICOS ESPECIAIS EM DEMOGRAFIA E ESTUDOS
POPULACIONAIS**

Laboratório Final

Aracaju – SE
2026

LABORATÓRIO FINAL - ANÁLISE DE DADOS SOCIODEMOGRÁFICOS COM R STUDIO E L^AT_EX

Orientações: O objetivo deste laboratório é avaliar dois aspectos fundamentais. A primeira delas diz respeito a habilidade em lidar com bases de dados e, por decorrência, extrair informações relevantes. Em segundo lugar, observar a capacidade analítica de cada um frente aos dados.

Estão disponíveis dois conjuntos de bases de dados. O primeiro, composto pelos arquivos *.csv, quais sejam:

- familias_cadunico_2025;
- familias_por_condicao_pbf_2025;
- pessoas_benef_pbf_2025;
- pessoas_cadun_sexo_2005;
- valores_pbf_2025;

Essas bases de dados foram obtidas diretamente do site oficial do Governo Federal: <<https://aplicacoes.cidadania.gov.br/vis/data3/data-explorer.php>> e foram salvas em formato original (*.csv).

A segunda base de dados utilizada é o Sistema IBGE de Recuperação Automática - Sidra, que também permite acessar dados municipais. Dessa fonte, extraímos via API duas bases de dados

- a Taxa de alfabetização das pessoas de 15 anos ou mais de idade (Tabela 9543), cuja seleção de variáveis foi: Sexo = total, Cor ou raça = total, Idade = total, Nível territorial = Sergipe e municípios brasileiros (todos os 5.571). Recomendo que você mesmo gere esse link, mas, para facilitar os trabalhos, segue: <"t/9543/n3/28/n6/all/v/all/p/all/c2/6794/c86/95251/c287/100362/d/v2513%20">.
- População municipal por sexo (Tabela 9514), com a seguinte seleção: Sexo = Homem ou Mulher, Idade = total, Nível territorial = Municípios brasileiros (todos os municípios). Recomendo que você mesmo gere esse link, mas, para facilitar os trabalhos, segue: <"t/9514/n6/all/v/allxp/p/all/c2/allxt/c287/100362/c286/113635">.

As bases acima devem ser importadas para o R Studio como objetos. A propósito, sugiro nomeá-los conforme abaixo.

- familias_cadunico: 825 observações e 5 variáveis;
- familias_cond_pbf: 825 observações e 7 variáveis;

- pessoas_benef_pbf_2025: 900 observações e 6 variáveis;
- pessoas_cadun_sexo: 825 observações e 6 variáveis;
- valores_pbf: 900 observações e 10 variáveis;
- tx_alfab_mun: 5.571 observações e 17 variáveis;
- pop_mun: 11.140 observações e 17 variáveis

Observe também que esses objetos variam quanto ao número de observações e de variáveis. Isto indica a necessidade de proceder alguns ajustes nos dados originais de tal forma que sejam obtidas informações para cada um dos 75 municípios sergipanos. Observe, por exemplo, que o número de pessoas beneficiadas pelo PBF é apresentado por mês e, neste caso, devemos obter o número médio anual de beneficiários para cada município.

1 Características em avaliação

O aluno deverá demonstrar habilidades em:

- Lidar com bases de dados de diferentes estruturas;
- Apresentar soluções para superar eventuais fragilidades dos dados;
- Descrever e analisar os principais resultados;
- Mostrar conhecimento na confecção de tabelas e gráficos;
- Demonstrar autonomia em pesquisa, inclusive buscando outros dados municipais que se mostrem pertinentes;
- Compor relatório sintético a partir dos dados, em *.pdf;
- Apresentar os resultados em Beamer.

2 Questões norteadoras

Vale reforçar a importância de leitura sistemática e realização de exercícios, além do que é visto em sala de aula. Como referência, destaco as obras de Wickham e Grolemund (2019), Perlin (2021), Davies (2016), Peruzzo (2019)

2.1 Construção do data frame

Crie uma base de dados estruturada (data frame) por município de Sergipe, com as seguintes variáveis:

1. `cod_mun` : Código do município (seis dígitos);
2. `nome_mun` : Nome do município;
3. `qte_fam_cadun` : Da base de dados `familias_cadunico_2025`, obtenha a Quantidade de famílias inscritas no cadastro único;
4. `qte_fam_pobre_renda_pbf` : Da base `familias_por_condicao_pbf_2025`, obtenha Quantidade de famílias no cadastradas no CadÚnico com renda per capita até meio salário mínimo (pobreza + renda);
5. `qte_pess_benef_pbf`: Da base `pepsoas_benef_pbf_2025`, obtenha o número de pessoas beneficiárias no PBF (a partir de março de 2023);

6. `qte_homens_cadun`: Da base `peessoas_cadun_sexo_2005`, obtenha a quantidade de homens inscritos no CadÚnico;
7. `qte_mulheres_cadun`: Da base `peessoas_cadun_sexo_2005`, obtenha a quantidade de mulheres inscritos no CadÚnico;
8. `qte_fam_benef`: Da base `valores_pbf_2025`, obtenha a quantidade de famílias beneficiadas (a partir de março de 2023);
9. `valor_medio_benef`: Da base `valores_pbf_2025`, obtenha o valor do benefício médio (a partir de março de 2023);
10. `qte_pop_masc`: Da API (Tabela 9514), obtenha a população masculina;
11. `qte_pop_fem`: Da API (Tabela 9514), obtenha a população feminina;
12. `tx_alfab`: Da API (Tabela 9543), obtenha a taxa de alfabetização total;

2.2 Integração dos dados

A integração de dados é uma parte importante em qualquer estudo, mormente na demografia. Assim, integre os sete *data frames* acima de forma a obter um arquivo com todas as variáveis descritas na 2.1. Para facilitar, sugiro que o arquivo integrado seja denominado `base_lab`.

3 Questões

Os resultados obtidos com os procedimentos a seguir, devem ser descritos no $\text{\LaTeX}$.

1. Considerando a variável que mensura a proporção de pessoas alfabetizadas nos municípios, `tx_alf`, classifique essas áreas em baixa alfabetização (1º quarto), média baixa (2º quarto), média alta (3º quarto) e alta (4º quarto).
Com base nessa classificação, elabore uma tabela com todos os municípios sergipanos, por ordem decrescente da taxa de alfabetização e descreva resumidamente os resultados. Avalie se essa é a melhor forma de apresentação tabular.
2. Com base na população por sexo, obtenha a população total. Em seguida, calcule a proporção de residentes no município que é beneficiada pelo Programa Bolsa Família (2025). A partir desse indicador, classifique a população municipal em quartos, como no item anterior.

3. Com base nos resultados anteriores, construa um diagrama de dispersão com base nas taxas de alfabetização e na proporção de pessoas beneficiadas pelo Bolsa Família. Você consegue identificar algum padrão que sugira algum tipo de relação? (Dica: Para excelentes exemplos de gráficos do ggplot, visitem <<https://ggplot2.tidyverse.org/>>)
4. Represente em boxplot o valor do PBF (valor_medio_repasse_fam) e por classes de participação. Descreva como esses valores se distribuem (existe outlier nessas classes, ou seja, valores que destoam dos demais quanto ao valor médio?)

Referências

DAVIES, T. M. *The book of R: a first course in programming and statistics*. [S.l.]: No Starch Press, 2016.

PERLIN, M. S. Análise de dados financeiros e econômicos com o r-versão online. 2021.

PERUZZO, J. *Uso do LaTeX na Elaboração de Trabalhos Acadêmicos*. 1. ed. Brasil: Independente, 2019. Capa flexível, publicado em 28 de outubro de 2019, texto em português.

WICKHAM, H.; GROLEMUND, G. *R for data science: import, tidy, transform, visualize, and model data*. [S.l.]: "O'Reilly Media, Inc.", 2019.